

Farbweg und Expertenauswahl

Was Sie erzählen, und was Sie darunter wissen müssen — GDRNPP im Detail, Pipeline A, Schattenbasierte Expertenauswahl.

Sprecher: Maximilian Klattig · 7 Blätter · Stand 4. August 2026 · Quellen: Seminararbeit (29 S., 1. August 2026), Deck `kip.html`, Trainingskonfiguration `config_base_so.py`, Konverter `isaac_to_bop.py`, Eval-Reports `results/icbin_t109/`, GDR-Net (arXiv 2102.12145) und GDRNPP-Repository.

Dieses Papier ist zum Hineinlesen gedacht, nicht zum Vorlesen. Teil 0 ist Ihr Auftritt in Kurzform. **Teil 1 erklärt bei Null beginnend, was das System überhaupt tut** — mit Bildern statt Formeln und einem Glossar am Ende. Teil 2 geht dann so tief in GDRNPP, dass Sie auf jede Nachfrage zu Architektur, Labels und Training antworten können. Teil 3 und 4 sind Ihre beiden inhaltlichen Blöcke. Teil 5 ist der Fragenkatalog mit fertigen Antworten, Teil 6 der Zahlenspiegel. Teil 7 nennt drei Stellen, an denen ein aufmerksamer Zuhörer Sie festnageln kann — mit vorbereiteter Antwort.

0	Ihr Auftritt	4	Die Expertenauswahl
1	Von Null erklärt	5	Fragenkatalog
2	GDRNPP im Detail	6	Zahlenspiegel
3	Der Farbweg (Pipeline A)	7	Drei Schwachstellen, vorbereitet

0 Ihr Auftritt

Sie sprechen zwei zusammenhängende Blöcke, dazwischen liegt Yannics Tiefenweg und der Vergleich. Ihr erster Block erklärt, wie ohne Tiefe eine genaue Lage entsteht. Ihr zweiter Block löst den Konflikt auf, den der Vergleich davor aufgemacht hat.

Ihre Blätter im Register, in der Reihenfolge des Vortrags

BLATT	KERNSATZ, DEN DAS PUBLIKUM MITNEHMEN SOLL	CA.
Farbweg: die Idee	Die Tiefe wird bewusst nicht benutzt; was sie liefern würde, holt die bekannte Tischebene aus der Geometrie. Aus sechs Freiheitsgraden werden praktisch drei.	1,5 min
Farbweg: Umsetzung	Orientierte Box statt achsparalleler, dann je Bauteilkategorie ein eigenes GDRNPP-Modell, dann ein Adapter in Weltkoordinaten mit Aufsetzen auf die Ebene.	2 min
Farbweg: Ergebnis	AR 0,886 und rund 4 mm Lagefehler bei einer Schwelle von 11 mm. Den Ausschlag gibt das bauteilspezifische Training — und genau das ist auch der Preis.	1,5 min
→ Übergabe an Yannic: „Damit ist der Farbweg an seiner Grenze. Yannic zeigt jetzt, was die Tiefe stattdessen kann.“		
Expertenauswahl: die Idee	Es ist keine Konkurrenz zwischen zwei Verfahren, sondern eine Ortsfrage. Der Arm wirft einen Infrarot-Schatten; dort gibt es überhaupt keine Tiefe.	2 min
Expertenauswahl: Umsetzung	Die Schattenkarte wird vorab rein geometrisch berechnet. Entscheidend ist die Schnittmenge: keine Tiefe, aber Farbkamera sieht noch hin — 485 cm², 13,3 %.	2 min

BLATT	KERNSATZ, DEN DAS PUBLIKUM MITNEHMEN SOLL	CA.
Das System dahinter	Zwei einheitliche Schnittstellen, /segment und /pose . Deshalb sind Erkennung und Lage frei kombinierbar, und die Auswahl greift an genau einer Stelle ein.	1,5 min
Expertenauswahl: Ergebnis	Im Schatten 424,6 mm → 3,4 mm. Außerhalb greift die Auswahl nicht ein und der Tiefenweg bleibt unverändert.	1,5 min

→ Übergabe an Jerun: „Damit steht die Lösung. Jerun ordnet ein, was das wert ist und wo die Grenzen liegen.“

DER EINE SATZ, FALLS SIE NUR EINEN SAGEN DÜRFTEN

Farbbild und Tiefenbild sind keine Konkurrenten, sondern örtlich ergänzende Experten — der Farbweg ist überall verfügbar und dank bauteilspezifischem Training auf rund vier Millimeter genau, der Tiefenweg ist genauer, wo Tiefe ankommt, und im Infrarot-Schatten des Arms blind.

1 Von Null erklärt

Dieses Kapitel setzt nichts voraus. Wer es gelesen hat, versteht, was das System tut, warum es überhaupt schwierig ist und was die Zahlen bedeuten. Der Deepdive ab Kapitel 2 setzt genau hier auf.

1.1 Worum es eigentlich geht

Auf einem Montagetisch liegen Metallteile. Ein Roboterarm soll sie greifen. Damit er das kann, reicht es nicht zu wissen, dass dort ein Anker liegt. Der Greifer muss angefahren werden — er braucht die genaue Stelle und die genaue Drehlage.

DAS BILD, DAS IMMER FUNKTIONIERT

Stellen Sie sich vor, Sie beschreiben jemandem am Telefon, wo die Fernbedienung liegt. „Auf dem Tisch“ genügt nicht, wenn die Person blind zugreifen soll. Sie müssten sagen: *30 cm vom linken Rand, 15 cm von vorne, flach aufliegend, Knöpfe nach oben, um 40 Grad gegen die Tischkante verdreht*. Das sind sechs Angaben — drei für den Ort, drei für die Drehung. Genau diese sechs Zahlen nennt man die **6D-Lage**, und genau die soll unser System aus einem einzigen Foto bestimmen.

1.2 Was die sechs Zahlen sind

WAS	WIE VIELE ZAHLEN	BEDEUTUNG IM KLARTEXT
Position	3	Wo auf dem Tisch, gemessen vom Tischnullpunkt: nach rechts, nach hinten, nach oben.
Orientierung	3	Wie das Teil verdreht ist: kippen, neigen, um die Hochachse drehen.

Weil die Teile flach auf einer bekannten Tischplatte liegen, sind zwei der drei Drehrichtungen und die Höhe praktisch schon festgelegt — ein liegendes Teil kann nicht schweben und nicht auf der Kante stehen. Von den sechs Zahlen bleiben damit real drei übrig: **zwei Koordinaten in der Ebene und die Drehung um die Hochachse**. Diese Vereinfachung ist keine Bequemlichkeit, sie ist der Grund, warum ein Verfahren ohne Tiefenmessung überhaupt konkurrenzfähig ist.

1.3 Warum das schwer ist

SCHWIERIGKEIT	ZUM ANFASSEN
Kein Muster auf der Oberfläche	Die Teile sind blankes, glänzendes Metall. Ein Gesichtserkennner findet Augen und Nase — auf einem Löffel gibt es nichts Vergleichbares wiederzuerkennen. Was das Verfahren sieht, sind Umriss und Lichtreflexe, sonst nichts.
Symmetrie	Halten Sie eine Kaffeetasse ohne Henkel hoch und drehen Sie sie. Niemand kann sagen, um wie viel Grad Sie gedreht haben — es gibt keine Antwort, nicht bloß keine erkennbare. Genau so sind unsere Anker um ihre Längsachse.
Der Arm steht im Bild	Der Roboter verdeckt seine eigenen Teile. Ein Teil, von dem nur ein Viertel zu sehen ist, muss trotzdem geschätzt werden.
Tiefe hilft auf Metall nur bedingt	Die Tiefenkamera misst über ein projiziertes Infrarot-Muster. Auf spiegelndem Metall verläuft es, und hinter dem Arm kommt es gar nicht an. Mehr dazu in 1.11.

1.4 Der Grundgedanke: wir kennen das Teil bereits

Der entscheidende Umstand ist, dass wir für jedes Bauteil das **CAD-Modell** haben — die exakte Konstruktionsgeometrie aus der Fertigung. Die Aufgabe ist deshalb nicht „Was ist das für ein Ding?“, sondern:

Wie muss ich mein bekanntes 3D-Modell im Raum hinstellen und hindrehen, damit es aus Sicht der Kamera genau so aussieht wie auf dem Foto?

Das ist ein Schattenspiel: Sie halten eine Figur vor eine Lampe und drehen sie so lange, bis der Schatten an der Wand mit einer Vorlage übereinstimmt. Ist die Figur bekannt und der Schatten deckungsgleich, kennen Sie ihre Lage. Alle Verfahren dieser Arbeit machen im Kern dieses Schattenspiel — sie unterscheiden sich nur darin, *wie* sie die richtige Stellung finden.

1.5 Drei Wege, dasselbe zu tun

WEG	WIE ES FUNKTIONIERT	BEI UNS
Probieren Rendern und Vergleichen	Modell versuchsweise hinstellen, ein Bild davon rechnen, mit dem Foto vergleichen, nachkorrigieren, wiederholen. Wie ein Schlüsselbund durchprobieren, bis einer passt. Sehr genau, aber es kostet Zeit — jeder Versuch muss gerechnet werden.	FoundationPose, rund 8 s je Bild
Katalog Vorlagen und Korrespondenzen	Vorab rund 160 Ansichten des Teils aus allen Richtungen rendern und ablegen. Im Betrieb die ähnlichste Ansicht heraussuchen und feinjustieren. Wie im Farbfächer den passenden Ton suchen. Schnell, aber nur so fein wie der Katalog.	GigaPose, rund 1,3 s
Auswendig gelernt Direkte Regression	Ein neuronales Netz hat an vielen Beispielen gelernt, wie das Teil in jeder Lage aussieht, und gibt die Antwort in einem Durchgang aus — ohne Suchschleife. Wie ein erfahrener Monteur, der auf einen Blick sagt, wie herum das Teil liegt.	GDRNPP, rund 1,0 s — unser Farbweg

Der Preis des dritten Wegs steht schon im Bild: Auswendig lernen muss man *je Teil*. Die beiden anderen brauchen nur das CAD-Modell und laufen sofort auch für ein Bauteil, das sie nie gesehen haben.

1.6 Was GDRNPP im Kern macht

Der Name steht für *Geometry-guided Direct Regression Network* — „geometrisch geführte direkte Regression“. Die drei Bestandteile in Alltagssprache:

- **Regression** heißt schlicht: Das Netz gibt Zahlen aus, keine Kategorien. Nicht „das ist ein Anker“, sondern „er liegt bei 312 Millimeter und ist um 41 Grad gedreht“.
- **Direkt** heißt: in einem Durchgang, ohne nachgeschaltete Suche.
- **Geometrisch geführt** ist der eigentliche Trick — und der lohnt eine eigene Erklärung.

DIE GLOBUS-ANALOGIE

Sie fotografieren einen Globus. Wenn Sie für jeden Bildpunkt sagen könnten, welches Land dort zu sehen ist — hier Portugal, hier Marokko, hier der Atlantik — dann wüssten Sie automatisch auch, wie der Globus steht. Die Zuordnung „Bildpunkt → Stelle auf dem Objekt“ *enthält* die Lage bereits.

Genau das malt GDRNPP: eine Karte, die jedem sichtbaren Bildpunkt seine Koordinate *auf dem Bauteil* zuweist. Nicht wo im Bild der Punkt liegt, sondern welche Stelle des Ankers dort zu sehen ist. Aus dieser dichten Zuordnung wird anschließend die Lage ausgerechnet.

Und weil das Netz diese Zwischenkarte tatsächlich malen muss, statt die sechs Zahlen aus dem Nichts zu raten, ist es „geometrisch geführt“. Es wird gezwungen, die Form des Teils zu verstehen, bevor es antwortet. Das ist der ganze Unterschied zu einem Netz, das man einfach auf die Antwort trainiert.

Der zweite Teil des Namens, **PP**, steht für „plus plus“: die überarbeitete Fassung, die 2022 den BOP-Wettbewerb gewann. Sie brachte ein moderneres Grundnetz und deutlich härtere Trainingsvariation mit.

1.7 Was Training hier bedeutet — und woher die Lösungen kommen

Ein Netz lernt aus Beispielen mit Lösung. Für unseren Fall hieße das: Tausende Fotos vom Montagetisch, und zu jedem Foto die exakte Lage jedes Teils auf den Millimeter genau. **Diese Lösungen von Hand zu erzeugen ist praktisch unmöglich** — man müsste jedes Teil auf jedem Foto vermessen.

Der Ausweg: Wir bauen die Montagezelle in einer Simulation nach — Tisch, Roboterarm, Beleuchtung, die echten CAD-Modelle. Dann lassen wir Teile hineinfallen und rendern ein Bild von oben. **Der Computer weiß die Lösung, weil er die Teile selbst hingelegt hat.**

DAS BILD DAZU

Es ist wie Vokabellernen mit Lösungsblatt — nur dass wir Vokabeln und Lösungsblatt selbst drucken, in beliebiger Menge und garantiert fehlerfrei. Für jedes gerenderte Bild fällt automatisch mit ab: die Lage jedes Teils, welche Bildpunkte zu welchem Teil gehören, wie viel davon der Arm verdeckt, und die Entfernung jedes Punktes. Das nennt man Label oder Referenzlage.

Der offensichtliche Einwand — „dann lernt das Netz doch nur die Simulation“ — ist berechtigt und heißt in der Fachsprache Domänenlücke. Zwei Dinge halten dagegen. Erstens verzerren wir die Trainingsbilder absichtlich stark: Helligkeit, Kontrast, Unschärfe, Rauschen, teils Graustufen. Ein Netz, das damit zurechtkommt, hängt nicht an den Feinheiten der Simulation. Zweitens ist das inzwischen der Normalfall — nahezu alle Spitzenverfahren des BOP-Wettbewerbs trainieren rein synthetisch. Dass die Prüfung an echten Aufnahmen bei uns noch aussteht, bleibt trotzdem die ehrlichste offene Stelle der Arbeit.

1.8 Ein Durchlauf, Schritt für Schritt

Was passiert, wenn ein Bild eintrifft:

Vom Foto zum CAD-Modell im Betrachter. Werte in der rechten Spalte sind typische Größenordnungen aus echten Läufen.

#	SCHRITT	WAS DABEI GESCHIEHT	BEISPIEL
1	Aufnahme	Eine Farbaufnahme von oben auf den Tisch.	1280 × 720 Bildpunkte
2	Teile finden YOLOv8-OB	Ein Detektor legt um jedes gefundene Teil ein <i>gedrehtes</i> Rechteck und sagt die Klasse dazu.	4 Funde: 2× Anker lang, 2× Zahnrad

#	SCHRITT	WAS DABEI GESCHIEHT	BEISPIEL
3	Ausschnitt	Aus jedem Rechteck wird ein quadratischer Ausschnitt geschnitten und auf feste Größe gebracht.	je 320×320
4	Lage schätzen GDRNPP	Für die Klasse „Anker lang“ wird das eigens dafür trainierte Modell aufgerufen. Es malt die Zuordnungskarte aus 1.6 und liest daraus die Lage ab.	Drehung und Verschiebung, bezogen auf die Kamera
5	Umrechnen	Ein Adapter rechnet von „relativ zur Kamera“ auf „relativ zum Tischnullpunkt“ um und setzt das Teil sauber auf die Tischebene auf.	$x = 312 \text{ mm}$, $y = 188 \text{ mm}$, 41° gedreht
6	Anzeigen	Der 3D-Betrachter im Browser setzt das echte CAD-Modell an genau diese Stelle in die nachgebaute Zelle.	gesamt rund 1,0 s je Bild

1.9 Was die Kennzahlen bedeuten

AR 0,886 — was heißt das?

Von 100 geschätzten Teilen liegen rund 89 innerhalb der erlaubten Toleranz. AR steht für *Average Recall* und ist die Standardkennzahl des BOP-Vergleichs, also des etablierten Maßstabs dieses Fachgebiets. Alle unsere Zahlen folgen ihm, damit sie mit veröffentlichten Ergebnissen vergleichbar sind.

Welche Toleranz?

Ein Zehntel des Bauteildurchmessers. Bei den Ankern mit rund 112 und 115 Millimeter Durchmesser sind das **etwa 11 Millimeter**. Beim kleineren Zahnrad entsprechend nur rund 5 Millimeter — kleine Teile werden also strenger bewertet.

Und die 4 Millimeter?

Das ist der typische tatsächliche Fehler unseres Farbwegs, also gut zwei Ein-Cent-Münzen übereinander. Anders gesagt: Wir liegen fast dreimal genauer, als die Bewertung verlangt. Deshalb ist AR 0,886 kein knappes Bestehen, sondern ein deutlicher Abstand zur Schwelle.

Warum bekommt das Zahnrad trotzdem nur 0,838?

Nicht weil es schlechter geschätzt wird, sondern weil bei ihm die Schwelle nur halb so groß ist. Derselbe Millimeterfehler zählt beim kleinen Teil als Fehlschlag und beim großen noch als Treffer.

1.10 Symmetrie — warum 83 Grad Fehler kein Fehler sind

Auf dem Anhangblatt steht ein roher Drehfehler von 83,3 Grad. Ohne Erklärung klingt das katastrophal. Es ist keiner.

Die Anker sind um ihre Längsachse drehbar — wie ein Bleistift. Drehen Sie einen Bleistift um seine Achse, sieht er unverändert aus. Fragt man nun „um wie viel Grad ist er gedreht?“, ist jede Antwort gleich richtig. Ein Verfahren, das 83 Grad sagt, während die Referenz 0 Grad notiert hat, hat sich nicht geirrt — **die Frage hatte keine eindeutige Antwort**.

Die Bewertung des BOP-Standards weiß das. Sie prüft jede erlaubte Symmetrielage und nimmt die günstigste. Bleiben dann noch Grad übrig, ist das ein echter Fehler. Bei uns sind es **7,2 Grad** statt 83,3. Damit man das rechnen kann, muss jede Symmetrie im Datensatz hinterlegt sein — und zwar richtig, sonst würde man dem Verfah-

ren Fehler ankreiden, die keine sind. Für uns heißt das: Anker und Ringmagnet frei drehbar um eine Achse, das Zahnrad in sieben Stufen.

1.11 Der Infrarot-Schatten

Die Tiefenkamera funktioniert nicht wie ein Auge, sondern wie ein sehr feiner Beamer mit Kamera daneben: Sie projiziert ein Infrarot-Muster auf den Tisch und misst, wie stark es verzerrt zurückkommt. Daraus folgt für jeden Bildpunkt seine Entfernung.

DAS BILD DAZU

Halten Sie im Kino die Hand in den Projektorstrahl — auf der Leinwand entsteht ein Schatten. Genau das macht der Roboterarm mit dem Infrarot-Muster. In diesem Schatten kommt kein Muster an, also gibt es dort **keinen Tiefenwert**. Nicht einen ungenauen, sondern gar keinen. Der Tiefenweg ist dort blind.

Die Farbkamera sitzt 15 Zentimeter neben dem Projektor. Sie ist keine Projektionsquelle, sondern schaut nur — und sieht deshalb in einen Teil dieses Schattens weiterhin hinein. Diese Fläche, auf der keine Tiefe ankommt, die Farbkamera aber noch hinsieht, sind **485 cm² oder 13,3 Prozent des Tisches**.

1.12 Die Idee der Expertenauswahl

Damit steht die Ausgangslage: Zwei Verfahren, jedes mit einem klaren Vorteil und einem klaren Ausfall. Der Tiefenweg ist genauer, wo Tiefe ankommt, und im Schatten unbrauchbar. Der Farbweg ist überall verfügbar, dafür etwas gröber und braucht je Teil ein eigenes Training.

Ein Handwerker mit zwei Zangen wählt nicht ein für alle Mal eine davon, sondern greift je nach Stelle zur passenden. Genau das tut unser System: Für jedes einzelne Bauteil wird anhand seiner Position auf dem Tisch entschieden, welches Verfahren zuständig ist. In der Bildverarbeitung heißt so etwas *Expertenauswahl*.

Der Haken, und zugleich die schönste Stelle der Arbeit: Um zu entscheiden, ob ein Teil im Schatten liegt, bräuhete man seine Position — die käme aus der Tiefe, die im Schatten aber gerade fehlt. Gelöst wird das rein geometrisch über die bekannte Tischebene; wie genau, steht in 4.3.

1.13 Begriffe in Alltagssprache

6D-Lage / Pose	Ort und Drehung eines Teils, zusammen sechs Zahlen.
CAD-Modell / Netz	Die Konstruktionsgeometrie des Bauteils als 3D-Datei.
Detektion	Teile im Bild finden und einrahmen — noch ohne Lage.
Segmentierung	Wie Detektion, aber pixelgenau umrandet statt nur eingerahmt.
OBB	Gedrehtes Rechteck statt achsparallelem — liegt enger an schrägen Teilen.
RGB / RGB-D	Nur Farbbild / Farbbild plus Entfernungsbild.
Label / Referenzlage	Die bekannte richtige Antwort zu einem Trainingsbild.
Synthetische Daten	Trainingsbilder aus der Simulation statt von der Kamera.
Domänenlücke	Der Unterschied zwischen Simulation und Wirklichkeit.
Backbone	Das große Grundnetz, das aus dem Bild Merkmale zieht.
Epoche	Ein vollständiger Durchlauf durch alle Trainingsbilder.
Überanpassung	Das Netz lernt die Trainingsbilder auswendig statt die Aufgabe.

Prüfpunkt	Zwischenstand des Trainings, gespeichert zum späteren Auswählen.
Inferenz	Das fertige Netz anwenden, im Gegensatz zum Trainieren.
PnP	Klassisches Rechenverfahren, das aus Punktzuordnungen die Lage bestimmt.
Regression	Zahlen vorhersagen statt Kategorien.
BOP	Der etablierte Vergleichsstandard für Lageschätzung: Datenformat, Datensätze, Bewertung.
AR	Die BOP-Hauptkennzahl: Anteil der Schätzungen innerhalb der Toleranz.
MSSD / MSPD	Zwei Fehlermaße: Abstand in 3D am Objekt / Abstand in der Bildebene.
Trainingsfrei	Verfahren, das ein neues Teil allein aus dem CAD-Modell erschließt.

2 GDRNPP im Detail

2.1 Wo das Verfahren steht

GDRNPP (Liu et al., TPAMI 2025) ist die weiterentwickelte Fassung von *GDR-Net — Geometry-guided Direct Regression Network* (Wang et al., CVPR 2021). Es gewann den Großteil der Preise beim BOP-Wettbewerb 2022 und steht unter Apache-2.0, ist also uneingeschränkt einsetzbar. Das ist neben der Genauigkeit der zweite Grund für die Wahl: FoundationPose ist genauer, aber nicht kommerziell nutzbar.

Methodisch gibt es drei Familien der Lageschätzung. **Rendern-und-Vergleichen** (FoundationPose) rendert Hypothesen und vergleicht sie mit dem Bild. **Vorlagen- und korrespondenzbasierte** Verfahren (GigaPose) suchen die ähnlichste vorgerenderte Ansicht. GDRNPP gehört zur **direkten Regression**: Ein Netz gibt die Lage unmittelbar aus, ohne Suchschleife. Deshalb ist es mit rund einer Sekunde je Bild schnell.

2.2 Das Problem, das GDR-Net gelöst hat

Die klassische Vorgehensweise war zweistufig: Ein Netz sagt 2D-3D-Korrespondenzen vorher, und ein PnP-Löser mit RANSAC rechnet daraus die Lage. Das ist genau, hat aber einen strukturellen Nachteil: **PnP mit RANSAC ist nicht differenzierbar**. Der Trainingsfehler der eigentlichen Zielgröße — der Lage — kann also nicht in das Netz zurückfließen. Das Netz wird auf Korrespondenzen optimiert, obwohl niemand Korrespondenzen will.

GDR-Nets Antwort ist das **Patch-PnP**: ein kleines, lernbares Netz, das den geometrischen Löser ersetzt. Damit ist die Kette vom Bild bis zur Lage durchgehend differenzierbar und wird Ende-zu-Ende trainiert. Die geometrischen Zwischenkarten bleiben erhalten — daher „geometry-guided“ — sie werden aber zusätzlich beaufsichtigt, nicht mehr an einen externen Löser übergeben.

WENN SIE ES IN EINEM SATZ BRAUCHEN

GDRNPP sagt für jeden sichtbaren Bildpunkt vorher, welcher Stelle auf dem CAD-Modell er entspricht, und ein kleines nachgeschaltetes Netz liest aus diesem dichten Zuordnungsfeld direkt die Lage ab — statt einen klassischen, nicht trainierbaren Löser zu benutzen.

2.3 Die Architektur in fünf Schritten

ROI-Zoom	Backbone	Geometriekopf	Patch-PnP	Lage
Ausschnitt auf feste Größe	ConvNeXt-B	vier dichte Karten	drei Faltungen, zwei FC	R und t

Schritt 1 — ROI-Zoom. Aus dem Detektionsrechteck wird ein quadratischer Ausschnitt geschnitten und auf eine feste Kantenlänge skaliert. Im Original sind das 256×256 , **bei uns 320×320** (Begründung in 2.9). Beim Training wird das Rechteck zufällig verschoben und skaliert — *Dynamic Zoom-In*, bei uns mit Randfaktor 1,5. Das macht das Netz unempfindlich gegen die Ungenauigkeit des Detektors, denn im Betrieb kommt die Box von YOLO und nicht aus der Referenz.

Schritt 2 — Backbone. Ein ConvNeXt-Base, auf ImageNet vortrainiert, Eingang dreikanalig, also reines RGB. Wir greifen nur die letzte Merkmalsstufe ab (`out_indices=(3,)`, 1024 Kanäle). Kein Tiefenzweig — er ist im Netz vorhanden, aber abgeschaltet.

Schritt 3 — Geometriekopf. Ein Dekoder blendet die Merkmale wieder auf und gibt vier dichte Karten aus, bei uns mit 80×80 Bildpunkten (im Original 64×64). Diese vier Karten sind der Kern des Verfahrens und in 2.4 einzeln beschrieben.

Schritt 4 — Patch-PnP. Die Karten werden gestapelt und durch drei Faltungsschichten mit Kernel 3×3 und Schrittweite 2 geführt, jeweils mit Gruppennormierung und Aktivierung. Das Ergebnis wird flachgelegt und über zwei vollverbundene Schichten auf 256 Werte verdichtet. Zwei parallele Ausgabeschichten liefern daraus die Drehung und die Verschiebung.

Schritt 5 — Lage. Ausgegeben wird die Rotation als 6D-Darstellung und die Translation in der SITE-Parametrierung; beides wird anschließend in die übliche Form `R_m2c`, `t_m2c` (Modell → Kamera, in Millimetern, OpenCV-Kamerakonvention) zurückgerechnet. Genau in dieser Form nimmt sie unser Adapter entgegen.

2.4 Die vier dichten Zwischenkarten

Was der Geometriekopf ausgibt — bei uns je 80×80 Bildpunkte

KARTE	INHALT	WOHER DIE VORGABE KOMMT	VERLUST
M_{XYZ} Objektkoordinaten	Für jeden Vordergrundpunkt seine 3D-Koordinate <i>auf dem Objekt</i> , normiert auf [0,1] über die Kanten der Objekt-Bounding-Box. Drei Kanäle.	Wird aus dem CAD-Modell an der Referenzlage gerendert. Bei uns online im Trainingsschritt (<code>XYZ_ONLINE=True</code>).	L1, nur auf sichtbaren Punkten
M_{SRA} Oberflächenregionen	Die Objektoberfläche wird in 64 Fragmente zerlegt; die Karte sagt je Punkt die Wahrscheinlichkeit über diese Regionen vorher (plus Hintergrund).	Fragmente über Farthest-Point-Sampling auf dem Netz; Zuordnung folgt aus <code>M_{XYZ}</code> .	Kreuzentropie
M_{vis} sichtbare Maske	Welche Punkte des Ausschnitts das Objekt <i>tatsächlich sichtbar</i> zeigen.	<code>mask_visib/</code> aus dem BOP-Datensatz.	L1
M_{full} amodale Maske	Wo das Objekt <i>wäre</i> , auch hinter dem Arm. Der zweite Maskenkopf ist eine GDRNPP-Neuerung gegenüber GDR-Net.	<code>mask/</code> , die volle Silhouette an der Referenzlage.	L1

WARUM DIE REGIONENKARTE ÜBERHAUPT EXISTIERT

Sie ist die Antwort auf die Symmetrie. Auf einem drehsymmetrischen Teil ist die Objektkoordinate eines Bildpunkts mehrdeutig — mehrere Stellen des Modells passen gleich gut. Eine reine Koordinatenregression würde dann auf den Mittelwert zwischen den möglichen Antworten gezogen und wäre systematisch falsch. Die Regionenkarte darf stattdessen einem Punkt *mehrere* Regionen mit geteilter Wahrscheinlichkeit zuweisen. Sie wirkt im Patch-PnP als Aufmerksamkeitssignal (`REGION_ATTENTION=True`) und entschärft damit genau die Mehrdeutigkeit, die unsere Anker mitbringen.

Zusätzlich bekommt das Patch-PnP die 2D-Bildkoordinaten des Ausschnitts als eigene Kanäle (`WITH_2D_COORD=True`). Erst dadurch enthält der Eingang beide Seiten der Korrespondenz: „welcher Bildpunkt“ und „welche Objektstelle“ — die Information, die ein klassischer PnP-Löser bekommen hätte.

2.5 Die Rotationsdarstellung: warum 6D und warum allozentrisch

Warum nicht Quaternion oder Eulerwinkel. Jede Darstellung einer Drehung mit vier oder weniger Werten hat Unstetigkeitsstellen: Zwei fast gleiche Drehungen können weit auseinanderliegende Werte haben. Ein Netz, das

solche Werte regressieren soll, muss an diesen Stellen springen, was es nicht sauber lernen kann. Die 6D-Darstellung — **die ersten beiden Spalten der Rotationsmatrix** — ist dagegen stetig. Die dritte Spalte ergibt sich aus dem Kreuzprodukt, orthonormalisiert wird per Gram-Schmidt. In unserer Konfiguration:

```
ROT_TYPE="allo_rot6d".
```

Warum allozentrisch. Das Netz sieht nur den herausgeschnittenen Ausschnitt, nicht dessen Position im Gesamtbild. Ein Teil am Bildrand erscheint dem Netz identisch zu demselben Teil in Bildmitte — die *egozentrische* Drehung relativ zur Kamera ist aber eine andere, weil sich die Blickrichtung geändert hat. Die *allozentrische* Drehung ist relativ zum Sehstrahl definiert und damit genau die Größe, die aus dem Ausschnitt allein bestimmbar ist. Nach der Vorhersage wird sie mit der geschätzten Verschiebung und den Kameraparametern in die egozentrische umgerechnet.

FALLS JEMAND FRAGT, WARUM DAS WICHTIG IST

Ohne die allozentrische Darstellung müsste das Netz aus einem Ausschnitt eine Größe vorhersagen, die im Ausschnitt gar nicht enthalten ist. Es würde also lernen, aus der Bildposition zu raten — bei unserer Aufnahme von oben mit 1280×720 Bildpunkten wäre der Fehler am Rand am größten. Es ist derselbe Gedanke wie bei der Tiefenkonvention: Erst die saubere geometrische Definition macht die Zahl fair.

2.6 Die Translationsdarstellung: SITE

Die Verschiebung wird nicht direkt in Millimetern regressiert, sondern **maßstabsinvariant** (Scale-Invariant Translation Estimate). Vorhergesagt werden drei Werte, die sich auf den Ausschnitt beziehen:

- δ_x, δ_y — wie weit der projizierte Objektmittelpunkt vom Mittelpunkt des Ausschnitts abweicht, in Anteilen von dessen Breite und Höhe.
- δ_z — die Entfernung, geteilt durch das Zoom-Verhältnis zwischen Ausschnittsgröße und ursprünglicher Boxgröße.

Der Grund ist derselbe wie oben: Nach dem Zuschneiden und Skalieren ist die absolute Bildposition verloren, und ein Teil, das doppelt so weit weg liegt, sieht nach dem Zoom identisch aus. Die drei δ -Werte sind dagegen aus dem Ausschnitt bestimmbar; die metrische Verschiebung wird danach mit Ausschnittsgröße, Zoom-Verhältnis und den Kameraparametern zurückgerechnet. In unserer Konfiguration heißt das `TRANS_TYPE="centroid_z"`.

2.7 Die Verlustfunktion

Der Gesamtverlust hat zwei Teile. Der **geometrische Teil** beaufsichtigt die vier dichten Karten (Zeile für Zeile in der Tabelle in 2.4). Der **Lageteil** beaufsichtigt das Ergebnis des Patch-PnP und ist *entflochten*, also in drei getrennte Terme zerlegt, damit ein Fehler in der Drehung nicht mit einem Fehler in der Tiefe verrechnet wird:

Die Verlustterme in unserer Konfiguration, alle mit Gewicht 1,0

TERM	ART	WAS ER BESTRAFT
XYZ_LW	L1, maskiert auf sichtbar	falsche Objektkoordinaten
MASK_LW	L1	falsche sichtbare Maske
FULL_MASK_LW	L1	falsche amodale Maske
REGION_LW	Kreuzentropie	falsche Regionenzuordnung
PM_LW , PM_LOSS_SYM=True	Punktabgleich, symmetriebewusst	Drehfehler, gemessen als mittlerer Abstand der Modellpunkte — minimiert über alle erlaubten Symmetrielagen
CENTROID_LW	L1	Versatz des projizierten Mittelpunkts (δ_x, δ_y)
Z_LW	L1	Entfernungsfehler (δ_z)

Die hervorgehobene Zeile ist für uns die wichtigste. `PM_LOSS_SYM` bedeutet: Der Drehverlust wird gegen *alle* zulässigen Symmetrielagen des Bauteils gerechnet und der kleinste Wert genommen. Ohne das würde das Training den Anker dafür bestrafen, dass er um seine eigene Längsachse verdreht ist — also für etwas, das gar kein Fehler ist. `PM_R_ONLY=True` heißt, dass dieser Term nur die Drehung bewertet; die Verschiebung ist über die beiden anderen Terme abgedeckt. Genau dieselbe Symmetriehandlung greift später bei der Bewertung — die Symmetriangaben kommen in beiden Fällen aus derselben Datei `models_info.json`.

2.8 Was GDRNPP gegenüber GDR-Net ändert

BEREICH	GDR-NET (2021)	GDRNPP (BOP 2022, TPAMI 2025)
Backbone	ResNet-34	ConvNeXt
Maskenköpfe	einer (sichtbar)	zwei (sichtbar + amodal)
Augmentierung	moderat	deutlich stärkere Domänenrandomisierung
Training	—	angepasste Lernrate, Gewichtsabfall, Sichtbarkeitsschwelle, Boxdefinition
Tiefenverfeinerung	—	optionaler Nachlauf: gerenderte gegen gemessene Tiefe
Ensemble	—	Zusammenführung mehrerer Vorhersagen

WICHTIG FÜR IHRE ANTWORT

Die optionale **Tiefenverfeinerung von GDRNPP** setzen wir bewusst nicht ein. Wir fahren `test_gdrn.sh`, nicht `test_gdrn_depth_refine.sh`. Sonst wäre der „Farbweg“ kein Farbweg mehr, und der Vergleich mit dem Tiefenweg wäre wertlos. Das ist eine bewusste Selbstbeschränkung, keine Lücke — und ein guter Satz, wenn jemand fragt, ob wir nicht mehr aus GDRNPP herausholen könnten.

2.9 Unsere konkrete Konfiguration

Alles Folgende steht in `box_src/gdrnpp/config_base_so.py`; die Konfigurationen je Bauteil erben davon und setzen nur den Datensatznamen und das Ausgabeverzeichnis.

Trainingskonfiguration, mit Begründung wo sie vom Standard abweicht

EINSTELLUNG	WERT	WARUM
-------------	------	-------

EINSTELLUNG	WERT	WARUM
Ausschnitt / Ausgabe	320 / 80	Standard ist 256 / 64. Das Zahnrad hat nur 49,9 mm Durchmesser und feine Merkmale; bei 64 Ausgabepunkten liegt die Zahnstruktur unter der Auflösung des Regionenrasters — die Drehung konvergierte nicht (Median 87°).
Backbone	timm convnext_base , vortrainiert, 3 Kanäle	RGB-only ist gesetzt; der Tiefenzweig bleibt aus.
Geometriekopf	TopDownDoubleMaskXYZ- RegionHead , 1024 → 64 Regionen	Doppelmaske, entspricht GDRNPP-Standard.
Patch-PnP	Gruppennorm, GELU, Region- nen-Aufmerksamkeit, 2D- Koordinaten an	—
Optimierer	Ranger, Lernrate $8 \cdot 10^{-4}$, Ge- wichtsabfall 0,01	GDRNPP-Standard.
Zeitplan	160 Epochen, flach dann Kosinus ab 72 %	Standard sind 100. Das Zahnrad brauchte länger; der größere randomisierte Datensatz rechtfertigt die Verlängerung.
Stapelgröße	16, gemischte Genauigkeit	Eine RTX 3090 mit 24 GB.
Hintergrundtausch	aus (Standard: 50 %)	Der Standard klebt zufällige VOC-Bilder hinter das Objekt. Unsere Renderings enthalten bereits die echte Szene mit Roboterarm und Störteilen — genau den Kontext, auf den es ankommt. Ihn zu ersetzen wäre die falsche Augmentierung.
Farbaugmentierung	90 %	Glänzendes, texturloses Metall hat kein verwertbares Eigenfarbsignal. Das Netz soll formorientiert werden, nicht texturorientiert. Die Kette enthält unter anderem Graustufenwandlung, Kontrast, Helligkeit, Unschärfe und Rauschen.
Sichtbarkeitsschwelle	0,20	Instanzen unter 20 % Sichtbarkeit fliegen bereits beim Konvertieren raus; der Lader ist auf denselben Wert gesetzt, damit das Band 20–30 % als Trainingssignal erhalten bleibt. Genau das ist der Bereich hinter dem Arm.
Prüfpunktauswahl	alle 10 Epochen, 20 behalten	GDRNPP hat keine Validierung während des Trainings und kein frühes Stoppen; die Kette würde blind die letzte Epoche ausliefern. Wir behalten stattdessen 16 gleichmäßig verteilte Stände und wählen den nach Validierungs-AR besten (model_best.pth). Das ist unsere Absicherung gegen Überanpassung.

2.10 Die Labels — was GDRNPP zum Training braucht

Das ist die Frage, die im Seminar am wahrscheinlichsten kommt. Antwort in einem Satz: **GDRNPP braucht kein einziges von Hand annotiertes Bild.** Alles kommt aus der Simulation, und die geometrischen Zielkarten werden zur Trainingszeit aus dem CAD-Modell und der bekannten Referenzlage gerendert.

Was der Konverter `isaac_to_bop.py` je Szene schreibt

DATEI	INHALT	WOZU GDRNPP ES BRAUCHT
<code>rgb/</code>	Farbbild, 1280×720	der einzige Netzeingang
<code>scene_gt.json</code>	<code>cam_R_m2c</code> , <code>cam_t_m2c</code> in mm, <code>obj_id</code>	die Referenzlage — daraus wird M_{XYZ} gerendert und der Lageverlust berechnet
<code>scene_gt_info.json</code>	Boxen, Pixelzahlen, <code>visib_fract</code>	Ausschnitt und Sichtbarkeitsfilter
<code>mask_visib/</code>	sichtbare Silhouette	Vorgabe für M_{vis}
<code>mask/</code>	volle Silhouette	Vorgabe für M_{full}
<code>scene_camera.json</code>	<code>cam_K</code> , <code>depth_scale</code> , Extrinsik	Umrechnung der SITE-Werte in metrische Verschiebung
<code>models/*.ply</code>	CAD-Netz in Millimetern	Rendern der Objektkoordinaten, Punktabgleich
<code>models_info.json</code>	Durchmesser, Ausdehnung, Symmetrien	der symmetriebewusste Verlust und die Bewertung
<code>depth/</code>	16-Bit-Tiefe	vom Farbweg nicht benutzt — liegt für den Tiefenweg im selben Datensatz

ZWEI DETAILS, DIE SIE PARAT HABEN SOLLTEN

Der Arm ist nie eine Instanz. Er trägt in der Szene kein semantisches Label und taucht deshalb in keiner Annotation auf. Er verdeckt aber — die Teile hinter ihm haben schlicht weniger sichtbare Bildpunkte und damit einen kleineren `visib_fract`. Verdeckung entsteht also von selbst und muss nicht modelliert werden.

Die Symmetrien sind gemessen, nicht angenommen. Anker kurz, Anker lang und Ringmagnet bekommen eine kontinuierliche Drehsymmetrie um die Y-Achse durch den Bauteilmittelpunkt. Beim Zahnrad wird die Ordnung aus dem Netz selbst ermittelt: Die Silhouette wird entlang der Symmetrieachse rasterisiert und die Periodizität der Ränder ausgewertet. Ergebnis ist **C7** — und zwar aus der inneren Siebenkeil-Nabe, nicht aus der Außenkontur, die praktisch eine glatte Scheibe ist. Für die Bewertung entstehen daraus 6 zusätzliche Drehmatrizen plus Identität, für die Anker werden die kontinuierliche Symmetrie zu 315 Transformationen diskretisiert.

2.11 Warum ein Modell je Bauteil

GDRNPP kann grundsätzlich mehrere Objekte in einem Modell führen. Wir trainieren dennoch *ein Modell je Klasse* (im Repository als „SO“, single object, geführt). Der Grund ist die Genauigkeit: Ein Netz, das nur eine Geometrie kennt, muss seine Kapazität nicht auf fremde Formen verteilen. Genau das ist die Erklärung für die vier Millimeter — und zugleich die ehrliche Kehrseite, die auf Ihrem Ergebnisblatt als letzter Punkt steht: Jedes neue Bauteil braucht ein eigenes Training, bevor der Farbweg es schätzen kann. Der Tiefenweg braucht dagegen nur das CAD-Modell.

2.12 Bekannte Grenzen des Farbwegs

- **Kein Maßstab aus dem Bild.** Die Entfernung muss aus dem Erscheinungsbild erschlossen werden. Der Rest wird über die Tischebene aufgefangen — deshalb ist die Ebenenbedingung kein Zusatz, sondern tragend.

- **Feine Merkmale kosten Auflösung.** Das Zahnrad ist der Beleg: erst 320/80 statt 256/64 machte die Drehung lernbar.
- **Echte Mehrdeutigkeit bleibt.** Bei teilweiser Sicht auf einen Anker kann die Drehlage objektiv nicht eindeutig sein. Das löst kein Weg allein auf.
- **Neues Teil heißt neues Training.** Siehe 2.11.

3 Der Farbweg (Pipeline A)

3.1 Die Idee — und warum sie zuerst gegen die Tiefe entschieden wurde

Die ursprüngliche Festlegung war ein reiner Farbweg, aus einem praktischen Grund: Auf glänzendem Metall rauscht das Tiefenbild durch Reflexionen, und im Infrarot-Schatten des Arms fehlt es ganz. Ein System, dessen Kern auf instabilen Tiefenwerten steht, wollten wir nicht bauen.

Den erwarteten Genauigkeitsnachteil fängt eine geometrische Zusatzbedingung auf: **Die Teile liegen auf einer bekannten, ebenen Fläche.** Damit sind Höhe und Kippung festgelegt, und aus der sechsdimensionalen Aufgabe bleiben praktisch drei Größen — zwei Koordinaten in der Ebene und die Drehung um die Hochachse. Das ist der Satz, der Ihr erstes Blatt trägt.

3.2 Die Kette

Farbbild	YOLOv8-OB	GDRNPP	Adapter	3D-Betrachter
von oben, 1280×720	gedrehte Rechtecke	je Klasse ein Modell	Welt + Aufsetzen	CAD an der Lage

Warum orientierte Boxen. Ein achsparalleles Rechteck um ein schräg liegendes, längliches Teil enthält sehr viel Hintergrund. Das gedrehte Rechteck mit Mittelpunkt, Breite, Höhe und Winkel schmiegt sich an die Kontur an. Nach dem ROI-Zoom auf 320×320 landet dadurch deutlich mehr Bauteilfläche im Ausschnitt — bei gleicher Rechenzeit mehr nutzbares Signal. Das ist der direkte Grund, warum Pipeline A auf YOLOv8-OB steht und nicht auf einem Standarddetektor.

EIN ARCHITEKTONISCHES DETAIL, DAS SIE KENNEN SOLLTEN

GDRNPP ist der **einzige Lagedienst, der nicht frei kombinierbar ist**. Er liest die orientierte Box direkt, nicht die Maske der anderen Erkennungsdienste, und ist damit fest an YOLOv8-OB gekoppelt. Das Gateway erzwingt diese Kopplung: Wer GDRNPP als Lagequelle wählt, bekommt automatisch YOLO-OB als Erkennung. Auf dem Systemblatt sagen Sie „frei kombinierbar“ — wenn jemand nachhakt, ist das die eine Ausnahme, und sie ist bewusst so verdrahtet, nicht vergessen.

3.3 Was der Adapter macht

GDRNPP liefert `R_m2c` und `t_m2c` in Millimetern in der OpenCV-Kamerakonvention. Der Adapter rechnet in einem Schritt in die Welt Darstellung des Betrachters um:

```
R_m2w = R_w2cT · R_m2c
t_m2w = R_w2cT · (t_m2c - t_w2c)
t_world = t_m2w / 1000 - table_origin
```

Ergebnis: Z-nach-oben-Welt, Ursprung im Tischnullpunkt, Einheit Meter. Danach folgen die Vereinheitlichung der Symmetrielage und das Aufsetzen auf die Tischebene.

Das Aufsetzen ist der Punkt, an dem die Ebenenbedingung aus 3.1 tatsächlich wirksam wird: Kein Teil schwebt, keines kippt in eine physikalisch unmögliche Lage. Wichtig für die Ehrlichkeit der Zahlen: **Bei der Bewertung ist das Aufsetzen abgeschaltet**, damit die reine Schätzgenauigkeit gemessen wird und nicht die Korrektur.

3.4 Das Ergebnis

Bewertung nach BOP, IC-BIN-Protokoll, Validierungssplit mit Referenzlage

KLASSE	AR	MSSD	MSPD	ø MM	INSTANZEN	SYMMETRIE
Anker lang	0,907	0,875	0,939	115,2	1253	kontinuierlich, 315 Lagen
Anker kurz	0,871	0,836	0,905	112,1	1306	kontinuierlich, 315 Lagen
Zahnrad	0,838	0,720	0,957	49,9	1484	C7, 7 Lagen
Beide Ankerklassen	0,886	—	—	—	—	Kennzahl im Vortrag

Dazu: mittlerer Lagefehler rund **4 mm** bei einer Schwelle von **11 mm** (ein Zehntel des Objektdurchmessers), symmetriebereinigter Drehfehler **7,2°** gegenüber roh 83,3°, Laufzeit **1,0 s** je Bild für Erkennung und Lage zusammen.

DIE ZAHL, DIE DAS ZAHNRAD ERKLÄRT

Beim Zahnrad fallen MSSD (0,720) und MSPD (0,957) weit auseinander. Übersetzt: Die Lage *im Bild* stimmt fast immer, der *dreidimensionale* Oberflächenabstand reißt häufiger die Schwelle. Das ist plausibel, denn die Schwelle ist ein Zehntel des Durchmessers — beim Zahnrad also nur rund **5 mm** statt 11 mm. Ein kleines Teil wird nach BOP schlicht strenger bewertet. Das ist ein starkes Argument, falls jemand das Zahnrad als Schwachstelle darstellt.

4 Die Expertenauswahl

4.1 Warum überhaupt

Der Vergleich davor hat ein unbequemes Ergebnis geliefert: FoundationPose erreicht auf der korrigierten Tiefe 0,968 und schlägt damit den trainierten Farbweg mit 0,886. Der naheliegende Schluss wäre, überall auf Tiefe zu setzen. Genau das geht nicht.

Die Zivid-Kamera bestimmt die Tiefe, indem sie ein **Infrarot-Muster** auf den Tisch projiziert und dessen Verzer- rung auswertet. Steht der Roboterarm im Strahlengang, wirft er einen Infrarot-Schatten. Dort entsteht *kein Tie- fenwert* — nicht ein schlechter, sondern gar keiner. Die Farbkamera sitzt 15 cm neben dem Projektor und sieht in Teile dieses Bereichs weiterhin hinein.

im Schatten: Farbweg

außerhalb: Tiefenweg

Damit ist die Frage keine Konkurrenz zwischen zwei Verfahren, sondern eine **Ortsfrage**. Für jedes Bauteil wird der Experte gewählt, der an dieser Stelle des Tisches überhaupt arbeiten kann. In der Bildverarbeitung heißt so etwas Expertenauswahl: mehrere spezialisierte Verfahren stehen bereit, ein Auswahlschritt entscheidet.

4.2 Die Schattenkarte

Der Schatten hängt allein von der Geometrie der Zelle ab — Kamerapositionen, Armstellung, Tischfläche. Er lässt sich deshalb **vorab und exakt berechnen**, statt ihn im Betrieb zu schätzen.

- Von der **Infrarot-Quelle** bei (300, 88, 1100) mm und von der **Farbkamera** bei (450, 88, 1100) mm werden Strahlen auf das Raster der Tischfläche geschossen (57–783 mm × 42–537 mm).
- Jeder Strahl wird gegen das Zellenmodell geschnitten. Dafür genügt das Standardverfahren von Möller und Trumbore für den Schnitt Strahl gegen Dreieck.
- Es entstehen zwei Flächen: wo *keine Tiefe* ankommt, und wo die *Farbkamera nicht hinsieht*.
- **Entscheidend ist die Differenz:** keine Tiefe, aber Farbkamera sieht noch hin. Nur dort muss überhaupt um- geschaltet werden.

BEREICH	FLÄCHE	ANTEIL
Infrarot-Schatten gesamt	1569 cm ²	42,9 %
Sichtschatten der Farbkamera	1435 cm ²	39,3 %
Auswahlbereich für den Farbweg	485 cm²	13,3 %

Die Karte gilt für genau eine Stellung von Kamera und Arm. Ändert sich eine davon, wird sie neu berechnet — das ist eine Sekunden- rechnung, kein Training.

4.3 Der Kniff: Auswahl ohne Tiefe

Hier steckt die eigentliche Pointe, und sie lohnt sich auf der Bühne. Um zu entscheiden, ob ein Teil im Schatten liegt, bräuchte man seine Position — die käme aus der Tiefe, die im Schatten aber gerade fehlt. **Ein Henne-Ei- Problem.**

Gelöst wird es rein geometrisch:

Bildposition vom Detektor	Sehstrahl über die Kameraparameter	Schnitt mit der Tischebene	Aufstandsstelle in Weltkoordinaten	im Auswahlbereich? Farbweg oder Tiefenweg
-------------------------------------	---	--------------------------------------	--	---

Der Detektor liefert die Bildposition. Daraus folgt der Sehstrahl. Weil die Tischebene bekannt ist — dieselbe Annahme, die schon den Farbweg trägt — liefert der Schnitt die vermutete Aufstandsstelle des Teils in Weltkoordinaten. **Ohne einen einzigen Tiefenwert.** Danach ist es ein simpler Test, ob dieser Punkt im Auswahlbereich liegt.

Zusätzlich gibt es eine **fähigkeitsbasierte Auswahl**: Bauteilklassen, für die noch keine Tiefenvorlagen existieren — aktuell das Zahnrad — laufen unabhängig von ihrer Lage immer über den Farbweg. So funktioniert jede Klasse an jeder Stelle des Tisches.

4.4 Das System dahinter

Die Auswahl ist deshalb so billig einzubauen, weil die Architektur darauf ausgelegt ist: Jeder Erkennungsdienst bedient `/segment`, jeder Lagedienst `/pose`, beide mit einheitlichem Ausgabeformat. Drei Erkennungs- und vier Lageverfahren ergeben rund zwölf sinnvolle Kombinationen — **die Expertenauswahl greift an genau einer Stelle ein**, im Gateway zwischen Stufe eins und Stufe zwei.

Die Dienste, wie sie tatsächlich laufen

Dienst	Stufe	Modalität	Anmerkung
YOLOv8-OBb	Erkennung	RGB	orientierte Boxen, Erkennung des Farbwegs
YOLO-seg	Erkennung	RGB	pixelgenaue Masken
SAM 3	Erkennung	RGB	trainingsfrei, aus Begriffs-Prompts
GDRNPP	Lage	RGB	je Bauteil trainiert, nativer Dienst
FoundationPose	Lage	RGB-D	trainingsfrei, nur als Vergleichsmaßstab
GigaPose	Lage	RGB und RGB-D	einsetzbare Tiefenvariante

Die GPU-Dienste laufen gemeinsam in einem Container-Verbund auf der Arbeitsstation. Der GDRNPP-Dienst und der zentrale Server liegen aus technischen Gründen nativ daneben: Die Umgebung mit detectron2 und den trainierten Prüfpunkten existiert bereits und funktioniert; ein Containerabbild dafür wäre rund 20 GB groß und würde einen bekanntermaßen mühsamen Bau reproduzieren, ohne etwas zu gewinnen. Der Betrachter im Browser spricht ausschließlich den zentralen Server an.

4.5 Dass es wirkt, ist gemessen — nicht behauptet

Damit die Wirkung des Schattens nicht nur an realen Bildern behauptet wird, bildet die Simulation ihn vollständig nach: Die gerenderte Tiefe wird *innerhalb* des Infrarot-Schattens vor der Lageschätzung ausgeblendet, rund **76.000 Bildpunkte je Bild**. Der Tiefenweg erlebt im Versuch damit dieselbe Blindheit wie an der realen Anlage. Das ist der methodisch wichtigste Satz Ihres Ergebnisblatts.

Lagefehler auf einem Testbild mit im Schatten ausgeblendeter Tiefe

Teil	Lage	Mit Auswahl	Nur Tiefenweg
Anker kurz	im Schatten	Farbweg, 3,4 mm	424,6 mm
Anker lang	außerhalb	Tiefenweg, 16,2 mm	9,4 mm

DIESE ZEILE WERDEN SIE ERKLÄREN MÜSSEN

Außerhalb des Schattens steht 16,2 mm gegen 9,4 mm — *mit* Auswahl also scheinbar schlechter. Die Auswahl greift dort aber gar nicht ein, beide Werte stammen vom Tiefenweg. Der Unterschied ist die normale Streuung der trainingsfreien Verfeinerung, die bei rund 30 bis 48 mm liegt; zwei Einzelmessungen desselben Verfahrens dürfen so weit auseinanderliegen. **Sagen Sie das aktiv dazu**, bevor jemand fragt — sonst liest die Tabelle sich, als koste die Auswahl außerhalb Genauigkeit.

5 Fragenkatalog

ZU GDRNPP

Was ist GDRNPP eigentlich, in einem Satz?

Ein Faltungsnetz, das aus einem Bildausschnitt für jeden sichtbaren Punkt vorhersagt, welcher Stelle des CAD-Modells er entspricht, und ein kleines nachgeschaltetes Netz liest aus diesem dichten Zuordnungsfeld unmittelbar die Lage ab.

Warum überhaupt ein lernbares PnP? Es gibt doch bewährte Löser.

Weil PnP mit RANSAC nicht differenzierbar ist. Der Lagefehler kann also nicht ins Netz zurückfließen, und das Netz wird auf Korrespondenzen optimiert statt auf das, was man eigentlich will. Das Patch-PnP macht die Kette durchgehend trainierbar.

Welche Zwischengrößen sagt das Netz vorher?

Vier dichte Karten mit je 80×80 Punkten: die Objektkoordinate je Punkt, eine Zerlegung der Oberfläche in 64 Regionen, die sichtbare Maske und die volle Maske einschließlich der verdeckten Teile.

Warum eine Regionenkarte, wenn es die Koordinatenkarte schon gibt?

Wegen der Symmetrie. Auf einem drehsymmetrischen Teil ist die Objektkoordinate eines Bildpunkts mehrdeutig; eine reine Regression würde zum Mittelwert zwischen den möglichen Antworten gezogen. Die Regionenkarte darf einem Punkt mehrere Regionen mit geteilter Wahrscheinlichkeit zuweisen und wirkt als Aufmerksamkeitssignal.

Wie wird die Drehung dargestellt?

Als die ersten beiden Spalten der Rotationsmatrix, sechs Werte. Quaternionen und Eulerwinkel haben Unstetigkeitsstellen, an denen ein Netz springen müsste. Die dritte Spalte folgt aus dem Kreuzprodukt.

Was heißt allozentrisch?

Die Drehung ist relativ zum Sehstrahl definiert, nicht relativ zur Kamera. Das Netz sieht nur den Ausschnitt und weiß nicht, wo im Bild er lag; die allozentrische Drehung ist genau die Größe, die aus dem Ausschnitt allein bestimmbar ist. Sie wird danach mit der Verschiebung und den Kameraparametern in die kameraseitige umgerechnet.

Und die Verschiebung?

Maßstabsinvariant: der Versatz des projizierten Mittelpunkts in Anteilen der Ausschnittsbreite und -höhe, und die Entfernung geteilt durch das Zoom-Verhältnis. Sonst müsste das Netz eine absolute Größe vorhersagen, die durch das Zuschneiden gerade verlorengegangen ist.

Wie geht das Training mit Symmetrie um?

Der Drehverlust wird gegen alle zulässigen Symmetrielagen gerechnet und der kleinste Wert genommen. Die Symmetrien stehen in `models_info.json` und werden von Training und Bewertung aus derselben Quelle gelesen.

Warum ConvNeXt und nicht ResNet?

Das ist eine der Änderungen von GDRNPP gegenüber GDR-Net, zusammen mit dem zweiten Maskenkopf und deutlich stärkerer Domänenrandomisierung. Wir fahren `convnext_base`, auf ImageNet vortrainiert.

Ihr habt die Auflösung erhöht — warum?

Standard sind 256 Bildpunkte Eingang und 64 Ausgang. Das Zahnrad hat 49,9 mm Durchmesser und feine Merkmale; bei 64 Ausgabepunkten liegt die Zahnstruktur unter der Auflösung, und die Drehung konvergierte nicht — Median 87 Grad. Mit 320 und 80 wurde sie lernbar. Das ist ein allgemeiner Hebel für kleine Teile, kein Trick für dieses eine Bauteil.

GDRNPP hat doch eine Tiefenverfeinerung. Warum nutzt ihr sie nicht?

Bewusst nicht. Sonst wäre der Farbweg kein Farbweg mehr und der ganze Vergleich mit dem Tiefenweg wertlos. Wir fahren die reine RGB-Auswertung.

Wie lange trainiert so ein Modell?

160 Epochen auf einer RTX 3090 mit 24 GB, Stapelgröße 16, gemischte Genauigkeit, Optimierer Ranger mit flachem Verlauf und Kosinus-Abklingen ab 72 Prozent. Je Bauteilkategorie ein eigener Lauf.

Wie wählt ihr den ausgelieferten Stand aus?

GDRNPP validiert nicht während des Trainings und stoppt nicht früh; die Standardkette würde blind die letzte Epoche ausliefern — bei 160 Epochen auf synthetischen Daten ein Überanpassungskandidat. Wir behalten deshalb 16 gleichmäßig über den Lauf verteilte Stände und wählen den mit dem besten Validierungs-AR.

ZU LABELS UND DATEN

Wie viele Bilder habt ihr von Hand annotiert?

Kein einziges. Alles kommt aus der Simulation in Isaac Sim, mit exakt bekannter Referenzlage, Maske, Tiefe und Begrenzungsrechteck. Genau deshalb ist der Ansatz überhaupt tragfähig — und die Spitzenverfahren des BOP-Wettbewerbs machen es genauso.

Welche Labels braucht GDRNPP konkret?

Farbbild, Referenzlage je Instanz, sichtbare und volle Maske, Begrenzungsrechteck mit Sichtbarkeitsanteil, Kameraparameter, das CAD-Netz in Millimetern und die Symmetrieangaben. Die geometrischen Zielkarten werden daraus zur Trainingszeit gerendert, sie liegen nicht als Datei vor.

Wird die Tiefe im Farbweg irgendwo benutzt?

Nein. Das Netz hat einen dreikanaligen Eingang, der Tiefenzweig ist abgeschaltet. Die Tiefe liegt im selben BOP-Datensatz, weil der Tiefenweg sie braucht.

Ist der Roboterarm annotiert?

Nein, er trägt kein semantisches Label und ist nie eine Instanz. Er verdeckt aber — die Teile hinter ihm haben weniger sichtbare Bildpunkte und damit einen kleineren Sichtbarkeitsanteil. Verdeckung entsteht von selbst.

Woher wisst ihr, dass das Zahnrad siebenzählig ist?

Gemessen, nicht angenommen. Die Silhouette wird entlang der Symmetrieachse rasterisiert und die Periodizität der Ränder ausgewertet. Die Außenkontur ist praktisch eine glatte Scheibe; die Ordnung sieben stammt aus der inneren Siebenkeil-Nabe.

Warum werden Instanzen unter 20 Prozent Sichtbarkeit verworfen?

Weil darunter kaum noch verwertbares Signal übrig ist. Wichtiger ist die Gegenrichtung: Der Bereich zwischen 20 und 30 Prozent bleibt *drin*, obwohl der Standard ihn wegwerfen würde. Genau das ist der Bereich hinter dem Arm, den das Netz lernen soll.

Warum tauscht ihr die Hintergründe nicht aus, wie es üblich ist?

Weil unsere Renderings bereits die echte Szene enthalten — Roboterarm, Störteile, Tisch. Zufällige Fremdbilder dahinterzukleben würde genau den Kontext zerstören, auf den es ankommt. Stattdessen augmentieren wir photometrisch sehr stark, damit das Netz formorientiert wird statt texturorientiert. Auf glänzendem, texturlosem Metall gibt es kein verwertbares Eigenfarbsignal.

ZUR BEWERTUNG

Was ist AR genau?

Der Anteil der Schätzungen, deren Lagefehler unter einer Schwelle bleibt, gemittelt über mehrere Fehlermaße: den dreidimensionalen Oberflächenabstand MSSD und den zweidimensionalen Projektionsabstand MSPD. Beide minimieren den Fehler über alle erlaubten Symmetrielagen. Maßgeblich ist das IC-BIN-Protokoll, weil dessen Griff-in-die-Kiste-Aufgabe unserer am nächsten kommt.

Warum ist der rohe Drehfehler 83 Grad, wenn das Verfahren gut ist?

Weil die Anker um ihre Längsachse drehsymmetrisch sind. Der rohe Wert misst eine Mehrdeutigkeit, keinen Fehler. Symmetriebereinigt bleiben 7,2 Grad.

Warum ist die Schwelle 11 mm?

Sie ist definiert als ein Zehntel des Objektdurchmessers; die Anker haben rund 112 und 115 mm. Beim Zahnrad mit 49,9 mm liegt sie entsprechend bei rund 5 mm — es wird also strenger bewertet.

Ist das Aufsetzen auf die Tischebene nicht ein Trick, der die Zahlen schön?

Es ist bei der Bewertung abgeschaltet. Gemessen wird die reine Schätzgenauigkeit. Im Betrieb ist es an, weil dort kein Teil schweben soll.

ZUR EXPERTENAUSWAHL

Warum nicht einfach immer das genaueste Verfahren?

Drei Gründe. Die Lizenz von FoundationPose ist nicht kommerziell. Es braucht rund acht Sekunden je Bild. Und im Infrarot-Schatten des Arms gibt es überhaupt keine Tiefe, dort ist es blind.

Wie entscheidet ihr, ob ein Teil im Schatten liegt, wenn dort die Tiefe fehlt?

Rein geometrisch. Aus der Bildposition folgt der Sehstrahl, der Schnitt mit der bekannten Tischebene liefert die vermutete Aufstandsstelle in Weltkoordinaten. Dafür ist kein einziger Tiefenwert nötig. Danach wird nur noch geprüft, ob dieser Punkt im Auswahlbereich liegt.

Wie verlässlich ist die Schattenkarte?

Sie ist rein geometrisch aus Kamerapositionen, Armstellung und Tischgeometrie berechnet, mit einem Standardverfahren für den Schnitt Strahl gegen Dreieck. Sie gilt für genau eine Konfiguration und wird bei Änderung neu berechnet. Der Abgleich mit der real gemessenen Schattenfläche steht noch aus — das ist eine der offenen Fragen.

Ist ein Auswahlbereich von 13 Prozent nicht ziemlich wenig?

Die 13,3 Prozent sind die Fläche, auf der die Auswahl überhaupt eingreifen muss. Der Infrarot-Schatten ist mit 42,9 Prozent viel größer; im Rest davon sieht auch die Farbkamera nicht hin, dort hilft kein Verfahren. Und die Wirkung auf dieser Fläche ist nicht klein: 424,6 mm gegen 3,4 mm.

Was passiert mit einem neuen Bauteil?

Der Tiefenweg braucht nur das CAD-Modell und läuft sofort. Der Farbweg braucht ein eigenes Training. Bis es vorliegt, greift die fähigkeitsbasierte Auswahl — so wie aktuell beim Zahnrad, für das noch keine Tiefenvorlagen

existieren und das deshalb immer über den Farbweg läuft.

Ihr sagt „frei kombinierbar“ — stimmt das wirklich?

Mit einer bewussten Ausnahme: GDRNPP liest die orientierte Box direkt statt einer Maske und ist deshalb fest an YOLO-OBB gekoppelt. Das Gateway erzwingt diese Paarung. Alle übrigen Kombinationen sind frei.

Ist die simulierte Tiefe nicht geschönt?

Gemessen wird korrekt und für alle Verfahren gleich. Offen ist allein die Domänenlücke: Die simulierte Tiefe ist nahezu ideal, die reale rauscht auf glänzendem Metall. Wie groß der Abstand ausfällt, zeigt erst der Test an echten Aufnahmen — das ist die wichtigste offene Frage der Arbeit.

6 Zahlenspiegel

Vergleich der Wege, Ankerklassen, je 100 Szenen, Absturzrate null

KOMBINATION	MODALITÄT	AR	DREHUNG	LAGE	LAUFZEIT
YOLO-OBb + FoundationPose	RGB-D	0,968	5,0°	36 mm	7,9 s
YOLO-OBb + GDRNPP (Pipeline A)	RGB	0,886	7,2°	4 mm	1,0 s
YOLO-OBb + GigaPose-3D	RGB-D	0,838	15,2°	30 mm	1,3 s
YOLO-OBb + GigaPose-2D	RGB	0,636	—	—	—
Mittel über alle Kombinationen			0,49 → 0,85 nach den Datenkorrekturen		

Zahlen, die Sie ohne Nachdenken parat haben sollten

AR Farbweg, beide Anker	0,886	Anker lang 0,907 · Anker kurz 0,871 · Zahnrad 0,838
Lagefehler Farbweg	≈ 4 mm	Schwelle 11 mm
Drehfehler Farbweg	7,2°	roh 83,3°
Laufzeit Farbweg	1,0 s	Erkennung und Lage zusammen
Tiefenkonvention-Fund	38 → 6 mm	kehrte den Vergleich um
Infrarot-Schatten	1569 cm²	42,9 % der Tischfläche
Sichtschatten	1435 cm²	39,3 %
Auswahlbereich	485 cm²	13,3 %
Wirkung im Schatten	424,6 → 3,4 mm	ein Teil, ein Testbild
Ausgeblendete Tiefe je Bild	≈ 76.000 px	Nachbildung in der Simulation
Ausschnitt / Ausgabe GDRNPP	320 / 80	Standard 256 / 64
Oberflächenregionen	64	Regionenkarte
Trainingsdauer	160 Epochen	je Bauteil, eine RTX 3090
Symmetrielagen	315 / 7	Anker kontinuierlich · Zahnrad C7
Kamera	Zivid L110+	Arm: Neura Lara5 mit Schunk-Greifer

7 Drei Schwachstellen, vorbereitet

1 · DER AR IST BEI UNS NICHT DAS MITTEL AUS DREI MASSEN

Im Grundlagenteil der Arbeit werden drei Fehlermaße genannt: VSD, MSSD und MSPD. In unserem Auswertungslauf ist **VSD abgeschaltet** (`vsd_enabled: false`); der berichtete AR ist das Mittel aus AR_{MSSD} und AR_{MSPD} . Wenn jemand nachrechnet, fällt das auf.

Antwort: „Wir berichten AR über MSSD und MSPD. VSD braucht eine Tiefenraasterung der Szene und ist in unserem Harness abgeschaltet — beide Wege werden aber unter exakt demselben Protokoll bewertet, der Vergleich bleibt also fair. Für den Farbweg wäre VSD ohnehin das systemfremde Maß.“

2 · 0,886 GEGEN DIE EINZELWERTE

Die abgelegten Berichte je Klasse geben 0,8706 und 0,9068 — Mittel 0,889. Im Deck und im Paper steht 0,886. Die Differenz von drei Tausendstel stammt aus unterschiedlichen Läufen und ist inhaltlich bedeutungslos, aber jemand mit Taschenrechner sieht sie.

Antwort: „Die 0,886 stammen aus dem im Paper berichteten Lauf; die Einzelwerte der abgelegten Berichte mitteln sich auf 0,889. Das ist Rundung und Laufstreuung, an der Aussage ändert es nichts.“

3 · „IHR HABT GEGEN EUCH SELBST EVALUIERT“

Training und Bewertung stammen beide aus der Simulation. Das ist der stärkste Angriff auf die Arbeit, und er ist teilweise berechtigt.

Antwort: „Bewertet wird auf einem getrennten Validierungssplit, den kein Modell gesehen hat, mit eigener Referenzlage. Die Domänenlücke zur Realität bleibt trotzdem bestehen und ist die erste Position unseres Ausblicks: ein kleiner realer Datensatz, durch beide Wege gemessen. Was wir hier zeigen, ist der saubere Vergleich der Verfahren untereinander — nicht die absolute Genauigkeit an der realen Anlage.“ Diesen Punkt nicht verteidigen, sondern zugeben und einordnen. Er steht ohnehin auf Jeruns Grenzenblatt.